

创智夏季营 · 具身智能方向实训考题

赛题：VLA/VA 模型长程操控基准测评

一、背景

具身智能（Embodied AI）是当前 AI 领域最具挑战性的前沿方向之一。**Vision-Language-Action (VLA)** 模型和 **World Model (WM)** 是两种主流技术路线，分别以“感知-语言-动作”端到端映射和“世界模型驱动动作预测”为核心理念。

StarVLA 是一个开源、模块化的具身智能框架（[GitHub](#)），支持 VLA 和 WM 两种路线下的多种模型架构（FAST、OFT、PI、GR00T 等），并提供统一的数据接口、训练流程和评测工具链。

CALVIN ABC→D 是长程机器人操控领域的标准基准，要求模型在训练环境 A/B/C 上学习，在**未见过的环境 D** 上完成 5 个连续任务链。该基准全面考察模型的泛化能力、长程规划能力和误差累积鲁棒性。

二、任务描述

参赛选手需基于 StarVLA 框架，选择合适的模型架构和训练策略，在 **CALVIN ABC→D** 基准上实现并测评一个 Action Policy Model。考核时间为 **2 天**。

三、具体要求

3.1 模型选择与实现

基座模型：选择以下之一作为视觉-语言骨干：

- **Qwen3.5 系列**（0.8B / 2B / 4B / 9B）—— 最新多模态大模型，StarVLA 已原生支持
- **CosmoPredict2**（2B）—— NVIDIA 世界模型路线，基于视频生成 DiT 架构

动作头架构：在 StarVLA 支持的以下架构中选择或组合：

- **FAST**：自回归离散 Action Token
- **OFT**：并行连续动作 MLP 头
- **PI**：Flow-Matching 扩散动作头
- **GR00T**：双系统架构（VLM System 2 + Flow-Matching System 1）

鼓励创新：在 StarVLA 框架下实现新架构（如 MOT、Mixture-of-Experts 动作头、自适应规划模块等），有**额外加分**。

3.2 数据与训练

预训练：鼓励基于公开数据集进行预训练，可选数据集包括但不限于：

- Open X-Embodiment (OXE)
- Bridge (WidowX)
- Fractal / RT-1
- LIBERO
- RoboCasa / RoboTwin 2.0

数据增强：鼓励采用数据增强策略（视觉增强、轨迹扰动、语言指令改写等）或自行构建更多训练数据。

后训练：基于 CALVIN 环境中的特定 Failure Pattern 进行针对性后训练（如 RL Post-Training、Failure-Aware Finetuning 等）。

3.3 测评与分析

在 CALVIN ABC→D split 上进行完整测评，报告以下指标：

- Task 1 ~ Task 5 各阶段成功率
- 平均任务链长度（Average Chain Length，满分 5.0）

技术路线论证：给出选择 VLA 或 WM 路线的原因，从以下维度分析：

- 数据效率
- 泛化能力（ABC→D 跨环境）
- 长程规划能力
- 计算成本与推理效率

Failure Pattern 分析：

- 记录并分类典型失败案例（如误差累积、环境泛化失败、长程规划退化、动作精度不足等）
- 分析失败根因
- 提出并实施改进方案（可以是后训练、架构改进、推理策略等）

四、交付物

1. **代码仓库：**Fork StarVLA 并提交所有修改代码，含清晰的 README
2. **模型权重：**上传至 HuggingFace 或提供下载链接
3. **测评报告：**包含完整的 CALVIN ABC→D 测评结果（Task 1~5 成功率 + 平均链长）
4. **技术文档：**技术路线选择论证 + Failure Pattern 分析报告

5. 答辩 PPT：10 分钟答辩展示

五、评分标准

总分 100 分，各维度权重如下：

- **测评指标 (30%)**：CALVIN ABC→D 平均任务链长度，Task 1~5 各阶段成功率
 - **技术方案 (25%)**：模型选择合理性、训练策略设计、创新性（新架构实现额外加分）
 - **Failure 分析 (20%)**：失败模式分类完整性、根因分析深度、改进方案有效性
 - **工程实现 (15%)**：代码质量、可复现性、文档完整度
 - **答辩表现 (10%)**：表达清晰度、技术深度、问答环节表现
-

六、参考资源

- **StarVLA 仓库**：github.com/starVLA/starVLA（建议使用 starVLA_dev 分支）
 - **StarVLA report**：[arXiv:2604.05014](https://arxiv.org/abs/2604.05014)
 - **预训练权重**：[HuggingFace StarVLA](#)（含 Qwen2.5-VL-3B-Action、Qwen3-VL-4B-Action 等）
 - **CALVIN 基准**：calvin.cs.uni-freiburg.de
 - **CosmoPredict2 文档**：StarVLA 仓库 docs/WM4A.md
 - **CALVIN 评测指南**：StarVLA 仓库 examples/calvin/
-

七、注意事项

- 鼓励团队协作，但每人需独立完成技术文档中的个人贡献说明部分。
- 选择 VLA 或 WM 路线均可，但需在技术文档中**详细论证选择原因**，并分析另一路线的优劣。